

Verificarea rețelelor neuronale folosind
alpha_beta_crown și NeuralSat pentru
benchmark-ul cGan al competiției VNN-Comp
2023

Diaconu Laura
Domșa Emanuel
Lapedulce Anastasia
Morariu Ioana-Alexandra
Romanet Rareș

Abstract

In this paper, we attempted to reproduce the results from the VNNCOMP-2023 competition, specifically focusing on the alpha-beta-CROWN and Marabou tools applied to the cGAN benchmark within the same competition. The paper begins with a brief description of how cGAN neural networks operate, followed by a characterization of the dataset and the steps taken to install the tools and run them. We analyzed the data obtained from the runs and compared them with those obtained in the competition. **TO DO: Maybe add a brief idea of the conclusions made after analysis**

Contents

1.	Introducere - Funcționarea rețelei neuronale	2
2.	Caracterizarea setului de date	4
3.	Instalarea și rularea tool-urilor	6
3.1	alpha-beta-CROWN	6
3.2	NeuralSAT	7
4.	Interpretarea rezultatelor	7
4.1	alpha-beta-CROWN	7
4.2	NeuralSAT	9
4.3	Compararea rezultatelor obținute pe cele două tool-uri . . .	11
5.	Rețelele neuronale în simularea provocărilor reale	14
6.	Concluzii	15
	Bibliography	16

1. Introducere - Funcționarea rețelei neuronale

Pentru a putea înțelege mai bine cum funcționează rețeaua neuronală din cadrul **Benchmark-ul cGAN al competiției VNN-Comp 2023** este necesar să înțelegem cum funcționează în general o rețea de tipul GAN, iar apoi una de tip cGAN.

- **GAN**(Generative Adversarial Networks) este un model neuronal mai special [1] a cărui concept poate fi reprezentat ca un joc între două rețele neuronale distincte adversare.
- **cGAN**(Conditional GAN) [2] ghidează procesul de creare a datelor prin încorporarea unor etichete specifice în GAN ca cele două rețele neuronale adversare să se poată orienta după acestea.

O reprezentare grafică a rețelei neuronale din cadrul Benchmark-ul cGAN al competiției VNN-Comp 2023 ar arăta în felul următor:

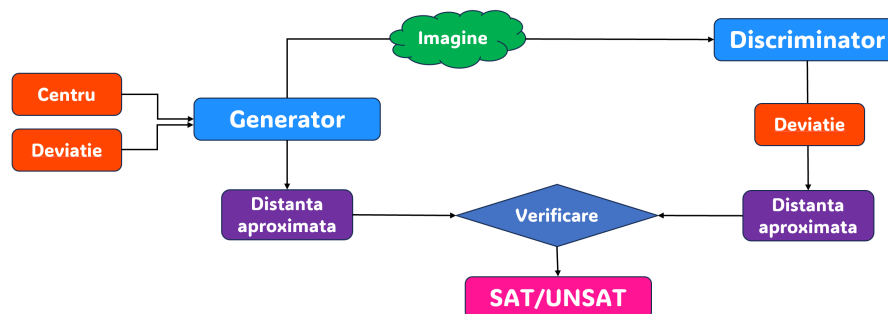


Figure 1: Reprezentare grafică a rețelei neuronale din cadrul Benchmark-ul cGAN al competiției VNN-Comp 2023

Conform schemei, Fig.1, în cazul acestei rețele neuronale cele două rețele distincte adversare se împart în:

- *Generatorul* - funcționează pe baza datelor de intrare(adică etichetele); are rolul de a genera o imagine cu un obstacol aflat la distanța data ca input.
- *Discriminatorul* - funcționează pe baza imaginii returnate de generator, are rolul de a aproxima distanța până la obstacol.

Iar datele de intrare sunt:

- *Etichetele* - sunt reprezentate de condiția de distanță și un vector de zgomot, care practic funcționează ca un fel de centru și o deviație

Evaluarea performanței acestei rețele se concentrează pe capacitatea ei de a genera conținut condiționat. În particular, verificarea se bazează pe alinierea distanței prezise de discriminator cu condiția distanței de intrare oferită de generator.

De exemplu, pentru o înțelegere mai clară, am construit următorul exemplu:

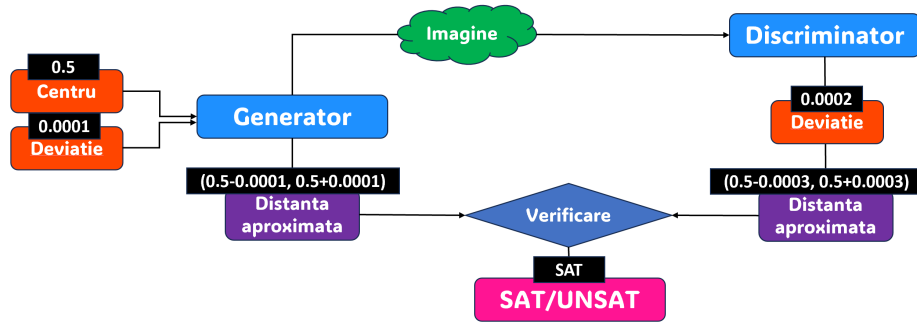


Figure 2: Reprezentare grafică a rețelei neuronale din cadrul Benchmark-ului cGAN al competiției VNN-Comp 2023 - exemplu de date de intrare

În exemplul de mai sus, Fig.2, să presupunem că pentru datele de intrare avem un centru de 0,5 și o deviație de 0,0001. Prin urmare, intervalul distanței la care se poate afla obstacolul este de $(0,5-0,0001, 0,5+0,0001)$.

Obiectivul nostru este să ne asigurăm că distanța prezisă de discriminator se potrivește cu acest interval. Mai exact, distanța prezisă de discriminator trebuie să se situeze în intervalul de intrare adăugând din nou o deviație, de data asta să zicem 0,0002, adică putem obține o distanță aproximativă în intervalul $(0,5-0,0003, 0,5+0,0003)$.

Dacă obținem din partea discriminatorului o distanță din acel interval, acest lucru indică faptul că **imaginile generate respectă condiția de distanță de intrare**.

Rezultatul acestei verificări este **satisfiabil** dacă se indică o **aproximare corectă a distanței de către discriminator**, în caz contrar se obține un rezultat **nesatisfiabil**.

2. Caracterizarea setului de date

Benchmark-ul cGAN aparține mulțimii de benchmark-uri din cadrul competiției VNN-COMP 2023 [3]. Acesta conține o rețea de tip generativă adversarială condiționată și un set de specificații. Benchmark-ul este folosit pentru a verifica corectitudinea și robustețea rețelei pe care o conține. În cadrul set-ului de date, există două tipuri de fișiere: .onnx (Open Neural Network Exchange) și .vnnlib. În fișierele .onnx sunt reprezentate rețele neuronale, acestea conțin informații necesare pentru a executa modelul neuronal. Fișierele .vnnlib conțin specificațiile ce trebuie respectate de rețeaua neuronală, astfel încât aceasta să fie corectă și robustă.

Atât fișierele .onnx cât și .vnnlib au o denumire sugestivă care să indice informații despre conținutul acestora.

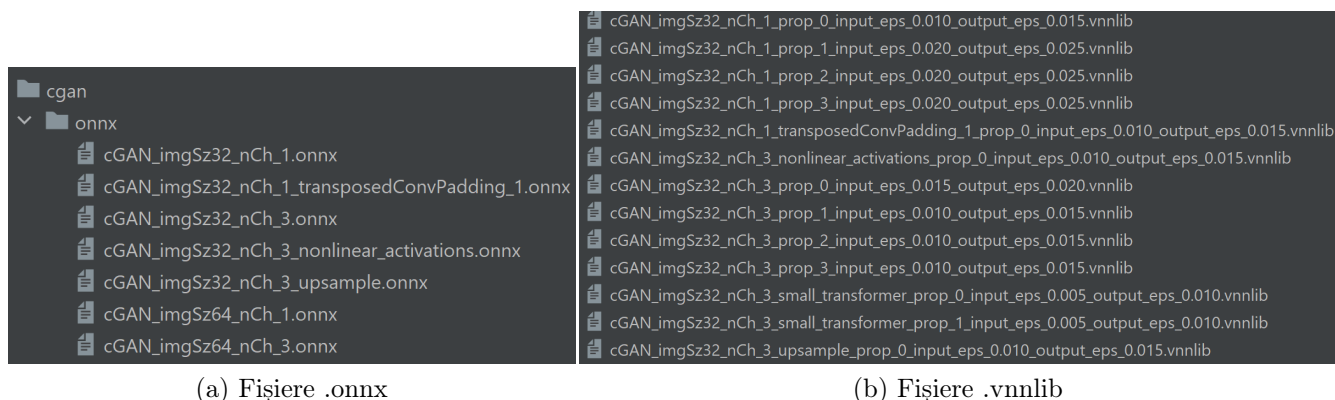


Figure 3: Fișierele benchmark-ului cGAN

- *CGan* - tipul de rețea neurală, în acest caz, o rețea generatoare adversarială condiționată.
- *imgSz32* - dimensiunea imaginii generate, în acest caz, o dimensiune de 32x32 pixeli.
- *nCh_1* - numărul de canale de culoare utilizate în imaginile de intrare sau de ieșire ale rețelei.
- *prop_0* - parametru/proprietate specifică a imaginii
- *input_eps_0* - valoare epsilon utilizată peste datele de intrare ale rețelei.
- *output_eps_0.015* - valoare epsilon utilizată peste datele de ieșire a rețelei.
- *transportedConvPadding_1* - tip specific de convoluție a rețelei.

- *nonlinear_activations* - rețeaua conține funcții de activare non-liniare între straturi.
- *upsample* - modelul neuronal efectuează operații de upsampling, care sunt utilizate pentru a mări dimensiunea spațială a imaginilor sau a datelor. Aceasta poate fi utilă în cazul modelelor generatoare pentru a genera imagini de rezoluție mai mare sau în alte scenarii în care este necesară mărirea dimensiunii datelor.

Toate fișierele .vnnlib au același conținut, diferențiindu-se prin valorile datelor.

Listing 1: Exemplu de cod SMT-LIB din fișierele vnnlib

```
(declare-const X_0 Real)
(declare-const X_1 Real)
(declare-const X_2 Real)
(declare-const X_3 Real)
(declare-const X_4 Real)

(declare-const Y_0 Real)

; Input constraints:
(assert (<= X_0 val_1_X0))
(assert (>= X_0 val_2_X0))

(assert (<= X_1 val_1_X1))
(assert (>= X_1 val_2_X1))

(assert (<= X_2 val_1_X2))
(assert (>= X_2 val_2_X2))

(assert (<= X_3 val_1_X3))
(assert (>= X_3 val_2_X3))

(assert (<= X_4 val_1_X4))
(assert (>= X_4 val_2_X4))

; Output constraints:
(assert (or
  (and (>= Y_0 val_1_Y0))
  (and (<= Y_0 val_2_Y0))
))
```

Luând în considerare succinta descriere a autorului benchmark-ului , din fișiere .vnnlib, am dedus următoarele:

- X_0 - reprezintă condiția de distanță ce este o variabilă cuprinsă între 0 și 1 și reprezintă normalizarea de la 0m la 30 m (de exemplu dacă condiția de distanță este 0,5, înseamnă că va fi generată o imagine ce are obstacolul la $0,5 \cdot 30m = 15m$)
- X_1 și până la X_4 - reprezintă valorile vectorului de zgomot care controlează mediul
- Y_0 - reprezintă distanța dată de către generator

3. Instalarea și rularea tool-urilor

Pentru a efectua rularea benchmark-ului cGan, am selectat cu atenție tool-urile alpha-beta-CROWN și NeuralSAT, inițial verificând dacă acestea pot procesa setul de date specificat. Am făcut această selecție pentru a realiza o comparație între primul tool care a obținut un timp de verificare eficient în timpul competiției și al doilea tool care a înregistrat cel mai ineficient timp de verificare. Alegerea a fost orientată de dorința de a evalua performanțele și eficacitatea fiecărui tool în contextul benchmark-ului cGan.

Ambele tool-uri au fost rulate folosind Python 3.11, pe sistemul de operare Ubuntu 20.04 prin Windows Subsystem for Linux (WSL) pe Windows 10. Am folosit un GPU de laptop NVIDIA GeForce RTX 3060.

3.1 alpha-beta-CROWN

Pentru a instala alpha_beta_CROWN am urmărit pașii de la capitolul *Installation and Setup* din fișierul de READ.ME gasit pe link-ul de github al tool-ului [4]. Suplimentar pașilor din ghid, am clonat submodulul *auto_LIRPA* în interiorul directorului alpha-beta-CROWN.

```
git clone https://github.com/Verified-Intelligence/auto_LiRPA.git alpha-beta-CROWN/auto_LiRPA
```

Următorul pas efectuat ce nu se regăsește în ghid, a fost crearea directorului `vnncomp2023_benchmarks` și clonarea repository-ului [5] în interiorul acestuia. Ulterior, am modificat **root path-ului** în fișierul `cgan.yaml` conform locației reale a directorului `cgan`.

La rularea tool-ului ne-am confruntat cu o eroare legată de lipsa librării `libcudnn_cnn_infer.so.8`. Adăugarea următoarei linii în fișierul `.bashrc` a rezolvat problema.

```
export LD_LIBRARY_PATH=/usr/lib/wsl/lib:$LD_LIBRARY_PATH
```

Comanda de rularea a tool-ului este redată mai jos.

```
python abcrown.py --config exp_configs/vnncomp23/cgan.yaml
```

În dependență de conținutul fișierului `cgan.yaml`, respectiva comandă are output diferit.

Cel mai dificil pas a fost remedierea erorii legate de libraria `libcudnn_cnn_infer.so.8`, fiind și pasul care a durat cel mai mult timp. Am rezolvat aceasta eroare folosind multiple sugestii gasite pe diferite platforme online [6].

3.2 NeuralSAT

Pentru instalare tool-ului NeuralSAT am urmărit cu strictețe pașii enumerați în ghidul găsit pe site-ul de github al tool-ului [7]. Efectuarea unor pași suplimentari nu a fost necesară.

Rularea tool-ului am făcut-o prin executarea următoarei comenzi:

```
python3 main.py --net "cGAN_imgSz32_nCh_3_upsample.onnx" --spec  
"cGAN_imgSz32_nCh_3_upsample_prop_0_input_eps_0.010  
_output_eps_0.015.vnnlib" --result_file result19.txt  
-- export_cex -- timeout1200
```

Ca și output, comanda de mai sus returnează un rezultat în fișierul dat ca argument, care va conține sat/unsat și timpul de verificare. Este important de menționat că rularea tool-ului NeuralSAT a implicat un consum mai mare de timp, deoarece a fost necesar să rulăm tool-ul pentru fiecare instanță în parte. În schimb, în cazul alpha-beta-CROWN, am putut procesa toate instanțele simultan.

4. Interpretarea rezultatelor

4.1 alpha-beta-CROWN

Pentru a putea interpreta datele rezultate le-am clasificat manual într-un tabel, precum cel din cadrul competiției pentru a putea face și o comparație între ele. Câmpurile de tabel sunt următoarele:

- **Benchmark:** Benchmark-ul pentru care avem înregistrate rezultatele.
- **neural network (ONNX):** Fișierul ONNX pentru care a rulat tool-ul.
- **specifications (VNNLIB):** Fișierul VNNLIB pentru care a rulat tool-ul.
- **results (vnncomp2023/us):** Poate avea valori sat/unsat; sat înseamnă că modelul îndeplinește condițiile din fișierul VNNLIB, adică distanța aproximată de discriminator este aceeași cu distanța pe care a primit-o generatorul ca și dată de intrare; unsat înseamnă că discriminatorul nu a reușit să facă o aproximare corectă. Prima coloană cu rezultate reprezintă rezultatele obținute în competiție, iar a doua coloană cu rezultate este obținută de noi.
- **time to verify (vnncomp2023/us):** Timpul de rulare a fișierului ONNX pentru specificațiile din fișierul VNNLIB, exprimat în secunde. Prima coloană reprezintă timpii obținuți în competiție, iar cea de-a doua coloană reprezintă timpii obținuți de noi.

În tabelul de mai jos se prezintă o analiză comparativă între rezultatele obținute în urma rulării proprii și cele obținute în cadrul competiției.

Benchmark	neural network (ONNX)	specification (VNNLIB)	results (vr)	results (us)	time to ve	time to ve
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	7.45	4.71
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	7.43	4.23
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	7.44	4.27
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	unsat	unsat	11.41	7.24
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	7.45	4.29
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	13.74	12.26
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	7.43	4.19
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	7.47	4.31
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	unsat	unsat	19.36	26.06
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	unsat	unsat	14.53	14.93
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	sat	sat	7.42	3.12
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	sat	sat	7.46	3.15
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	unsat	unsat	15.68	16.66
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	unsat	unsat	15.29	15.79
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	sat	sat	7.44	3.15
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	sat	sat	7.47	3.14
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	11.61	6.43
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	7.45	3.52
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	10.79	5.07

Figure 4: Comparare rezultate alpha-beta-CROWN

Conform tabelului prezentat în 4, este de remarcă faptul că pentru fiecare intrare, rezultatele (sat/unsat) au fost aceleași, atât pentru rezultatele rulării noastre, cât și pentru cele din competiție. Diferența dintre rezultatele din competiție și cele extrase de echipa noastră o constituie timpul de verificare. În tabel sunt evidențiați cu culoarea verde timpii mai reduși de verificare pentru aceleași instanțe.

Timpul de verificare înregistrat al echipei este în medie mai mic cu aproximativ 3 secunde pentru intrările unde rezultatul este satisfăcător. În schimb, pentru intrările cu rezultat nesatisfăcător timpul de verificare variază în funcție de instanțe, și anume: am obținut timpi mai mici de execuție pentru instanțele cu timp de execuție mai mic, iar pentru instanțele cu timp de execuție mai mare timpul înregistrat de noi a fost mai mare decât cel înregistrat în competiție.

Graficul prezentat mai jos, evidențiază și mai mult distribuția timpilor de execuție pentru fiecare instanță în parte.

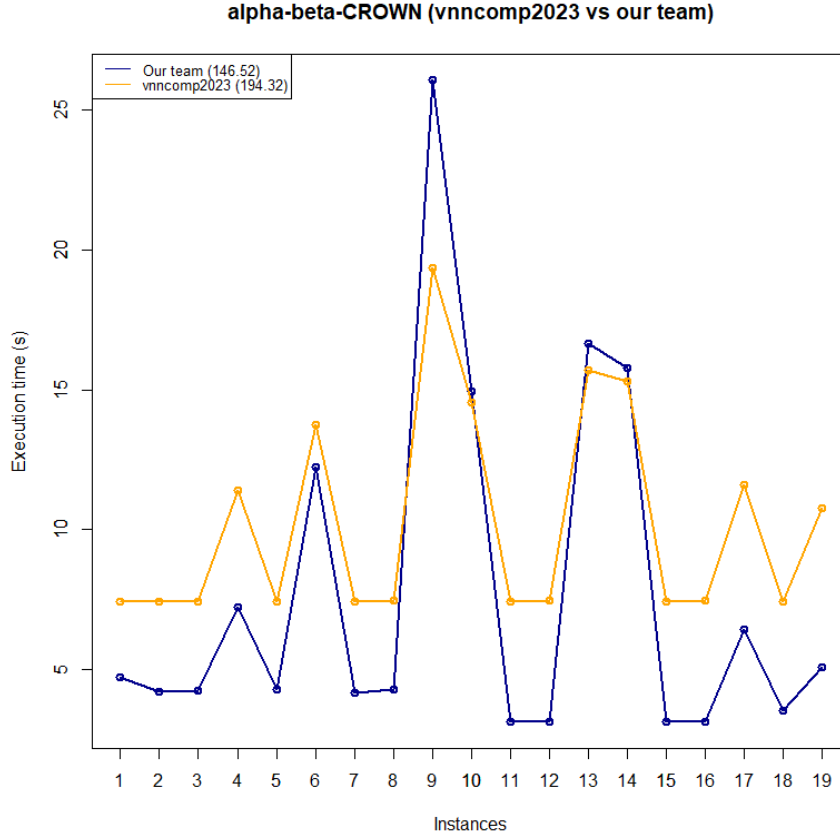


Figure 5: Comparare rezultate alpha-beta-CROWN

4.2 NeuralSAT

Pentru a putea interpreta datele rezultate le-am clasificat manual în tabel la fel ca și cele de obținute folosind alpha-beta-CROWN. Câmpurile de tabel sunt identice cu cele de la alpha-beta-CROWN, singura excepție fiind ocurența a două noi timpuri de rezultate, și anume:

- **results (vnncomp2023/us)**: Poate avea valori sat/unsat/unknown/error; pentru **sat** și **unsat** interpretările sunt la fel ca și în cazul alpha-beta-CROWN, pentru **unknown** înseamnă că proprietatea nu a putut fi demonstrată, iar **error** rezultă atunci când a avut loc o eroare în timpul rulării tool-ului. Prima coloană cu rezultate reprezintă rezultatele obținute în competiție, iar a doua coloană cu rezultate este obținută de noi.

În tabelul de mai jos se prezintă o analiză comparativă între rezultatele obținute în urma rulării proprii și cele obținute în cadrul competiției.

Benchmark	neural network (ONNX)	specification (VNNLIB)	results (v)	results (u)	time to ve	time to ve
cgan	cGAN_imgSz32_nCh_1.c	cGAN_imgSz32_nCh_1	sat	sat	4.15	2.79
cgan	cGAN_imgSz32_nCh_1.c	cGAN_imgSz32_nCh_1	sat	sat	4.11	2.68
cgan	cGAN_imgSz32_nCh_1.c	cGAN_imgSz32_nCh_1	sat	sat	4.1	2.7
cgan	cGAN_imgSz32_nCh_1.c	cGAN_imgSz32_nCh_1	unsat	unsat	20.07	13.74
cgan	cGAN_imgSz32_nCh_3.c	cGAN_imgSz32_nCh_3	sat	sat	4.09	2.92
cgan	cGAN_imgSz32_nCh_3.c	cGAN_imgSz32_nCh_3	unsat	unsat	813.17	59.65
cgan	cGAN_imgSz32_nCh_3.c	cGAN_imgSz32_nCh_3	sat	sat	4.06	2.77
cgan	cGAN_imgSz32_nCh_3.c	cGAN_imgSz32_nCh_3	sat	sat	4.09	2.88
cgan	cGAN_imgSz64_nCh_1.c	cGAN_imgSz64_nCh_1	unknown	unsat	13.63	159.81
cgan	cGAN_imgSz64_nCh_1.c	cGAN_imgSz64_nCh_1	unknown	unsat	12.82	150.88
cgan	cGAN_imgSz64_nCh_1.c	cGAN_imgSz64_nCh_1	sat	sat	4.1	3.02
cgan	cGAN_imgSz64_nCh_1.c	cGAN_imgSz64_nCh_1	sat	sat	4.07	3.01
cgan	cGAN_imgSz64_nCh_3.c	cGAN_imgSz64_nCh_3	unknown	unsat	13.49	157.76
cgan	cGAN_imgSz64_nCh_3.c	cGAN_imgSz64_nCh_3	unknown	unsat	14.1	169.16
cgan	cGAN_imgSz64_nCh_3.c	cGAN_imgSz64_nCh_3	sat	sat	4.11	3.14
cgan	cGAN_imgSz64_nCh_3.c	cGAN_imgSz64_nCh_3	sat	sat	4.12	3.26
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	25.97	24.09
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	4.07	3.11
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	error	unsat	5.87	25.37

Figure 6: Comparare rezultate NeuralSAT

Conform tabelului prezentat în 10

Graficul prezentat mai jos7, evidențiază și mai mult distribuția timpilor de execuție pentru fiecare instanță în parte.

Comparând coloanele de results am observat faptul că pentru toate instanțele am obținut valori satisfiabile sau nesatisfiabile. În schimb, competiția a obținut în cazul unor instanțe valori de *unknown*.

În cadrul graficului de mai jos, se pot observa diferențele dintre timpii de execuție.

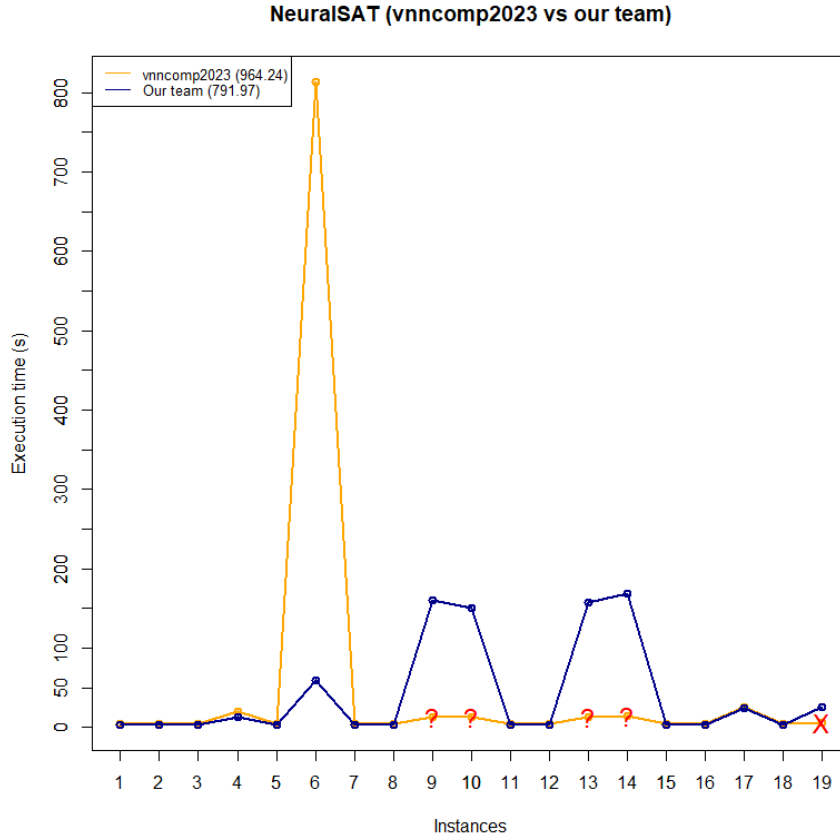


Figure 7: Comparare rezultate NeuralSAT

4.3 Compararea rezultatelor obținute pe cele două tool-uri

În urma rulării a tuturor fișierelor atât pentru alpha_beta_CROWN, cât și pentru NeuralSAT am obținut un număr de instanțe, pentru care timpul alocat verificării a fost depășit, egal cu 0. Prin urmare nu avem penalități pentru niciunul dintre tool-uri.

Totodată am obținut un Total verified egal cu 8, și un Total falsified egal cu 11 pentru ambele tool-uri. Pentru alpha_beta_CROWN rezultatele sunt identice cu cele din competiție. În cazul NeuralSAT, se poate observa că solver-ul a suferit îmbunătățiri în urma livrărilor constante făcute de dezvoltatori deoarece rezultatele obținute de noi au strâns un scor perfect de 100%, mult peste cel obținut de solver în cadrul competiției.

Din tabelul de mai jos putem să ne dăm seama (mai mult sau mai puțin) că formula de calculare a scorului este:

#	Tool	Verified	Falsified	Fastest	Penalty	Score	Percent
1	α - β CROWN	8	11	0	0	190	100%
2	NeuralSAT	8	11	0	0	190	100%

$$\rightarrow \text{Verified} \times 10 + \text{Falsified} \times 10 - \text{Penalty} \times 150$$

Procentajul reprezintă scorul obținut exprimat ca procent din scorul maxim posibil, oferind o imagine de ansamblu asupra performanței, iar formula de calcul este:

$$\frac{\text{Score} \times 100}{\max(\text{Score})}$$

Benchmark	neural network (ONNX)	specification (VNNLIB)	alpha-bet	NeuralSA	alpha-bet	NeuralSA
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	4.71	2.79
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	4.23	2.68
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	4.27	2.7
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	unsat	unsat	7.24	13.74
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	4.29	2.92
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	12.26	59.65
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	4.19	2.77
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	sat	sat	4.31	2.88
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	unsat	unsat	26.06	159.81
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	unsat	unsat	14.93	150.88
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	sat	sat	3.12	3.02
cgan	cGAN_imgSz64_nCh_1	cGAN_imgSz64_nCh_1	sat	sat	3.15	3.01
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	unsat	unsat	16.66	157.76
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	unsat	unsat	15.79	169.16
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	sat	sat	7.44	3.14
cgan	cGAN_imgSz64_nCh_3	cGAN_imgSz64_nCh_3	sat	sat	7.47	3.26
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	11.61	24.09
cgan	cGAN_imgSz32_nCh_1	cGAN_imgSz32_nCh_1	sat	sat	7.45	3.11
cgan	cGAN_imgSz32_nCh_3	cGAN_imgSz32_nCh_3	unsat	unsat	10.79	25.37

Figure 8: Comparare rezultate NeuralSAT vs alpha-beta-CROWN

Analizând datele din tabelul de mai sus, putem observa că în cazul instanțelor cu rezultat satisfiabil (sat) verificatorul NeuralSAT a obținut timpi puțin mai reduși de execuție decât alpha-beta-CROWN. Pe de altă parte, în cazul instanțelor cu rezultat nesatisfiabil (unsat) timpii de execuție obținuți de alpha-beta-CROWN sunt semnificativ mai reduși decât cei obținuți de NeuralSAT. Acest lucru este evidențiat și în graficul prezentat mai jos, graficul arată distribuția timpilor de execuție pentru ambele tool-uri, comparând instanța cu instanța.

Cel de al doilea grafic prezintă suma timpilor de execuție pe parcursul rulării tuturor celor 19 instanțe pe ambele verificatoare. Din acest grafic se poate trage concluzia că alpha-beta-CROWN este un tool mult mai eficient din punct de vedere a timpului de execuție.




Figure 9: Comparare rezultate NeuralSAT vs alpha-beta-CROWN




Figure 10

5. Rețelele neuronale în simularea provocărilor reale

Verificarea rețelelor neuronale este o etapă crucială în dezvoltarea și aplicarea acestor modele avansate. Este esențială din mai multe motive importante.

În primul rând, corectitudinea și fiabilitatea rețelelor neuronale sunt imperative. Ele sunt utilizate într-o varietate de domenii, de la medicină și tehnologie până la securitate cibernetică și vehicule autonome. Verificarea ne asigură că aceste rețele funcționează conform așteptărilor, oferind rezultate precise și fiabile într-o gamă largă de situații.

Siguranța reprezintă un alt aspect esențial. În domenii critice precum medicina sau industria automotive, erorile în funcționarea rețelelor neuronale pot avea consecințe grave. Verificarea este necesară pentru a identifica și remedia eventualele vulnerabilități care ar putea pune în pericol sistemul.

În industria auto, utilizarea învățării profunde și a viziunii artificiale pentru generarea de imagini noi joacă un rol esențial. Aceste tehnologii permit generarea de imagini sintetice pentru antrenarea și testarea vehiculelor autonome, simularea diverselor scenarii de conducere și optimizarea sistemelor de vizualizare și senzorilor. Ele contribuie la îmbunătățirea siguranței și eficienței în transporturi și la dezvoltarea vehiculelor autonome mai avansate. Utilizarea rețelelor neuronale în generarea de imagini pentru industria auto contribuie prin antrenarea eficientă a algoritmilor, simularea sigură a situațiilor de trafic și optimizarea senzorilor, accelerând dezvoltarea și îmbunătățirea vehiculelor autonome.

De asemenea, verificarea rețelelor neuronale contribuie la prevenirea bias-ului și discriminării. Aceste rețele pot fi influențate de prejudecăți încorporate în datele de antrenament. Prin teste și evaluări riguroase, putem identifica și corecta aceste bias-uri pentru a asigura obiectivitate și corectitudine în rezultatele obținute.

6. Concluzii

Această lucrare a evidențiat importanța folosirii Rețelelor Neuronale Generative Adversariale Condiționate (cGAN) în recunoașterea de imagini. Au fost oferite mai multe detalii legate de benchmark-ul cGAN, instalarea și rularea instrumentelor alpha-beta-CROWN și NeuralSAT și interpretarea rezultatelor obținute.

S-a analizat performanța și funcționarea rețelelor neuronale prin folosirea a două tool-uri importante: alpha-beta-CROWN și NeuralSAT.

Instrumentele folosite au avut rol în verificarea formală a corectitudinii rețelelor neuronale. S-a evaluat capacitatea rețelelor de a se alinia cu condițiile de intrare specificate.

Rezultatele în urmă rulării, au fost puse manual în tabele pentru a facilita compararea cu competiția. În compararea rezultatelor noastre cu cele din competiție, s-a observat o aliniere în ceea ce privește rezultatele satisfăcătoare sau nesatisfăcătoare. Diferențe au existat în schimb, la timpii necesari pentru verificare.

În concluzie, lucrarea a subliniat eficiența utilizării cGAN în contextul recunoașterii imaginilor. A analizat instrumentele de verificare neuronală și a evidențiat cât de importante sunt în dezvoltarea tehnologiilor de inteligență artificială.

Bibliography

- [1] A. Limarc, “What Is a Conditional Generative Adversarial Network? - DZone — dzone.com,” <https://dzone.com/articles/what-is-a-conditional-generative-adversarial-netwo>, 2023.
- [2] M. Mirza and S. Osindero, “Conditional generative adversarial nets,” *CoRR*, vol. abs/1411.1784, 2014. [Online]. Available: <http://arxiv.org/abs/1411.1784>
- [3] “vnncomp2023 benchmarks,” https://github.com/ChristopherBrix/vnncomp2023_benchmarks, [Accessed 15-02-2024].
- [4] “Read.me alpha-beta-crown,” https://github.com/feiyang-cai/alpha-beta-CROWN_vnncomp23/blob/master/README_abccrown.md, [Accessed 15-02-2024].
- [5] “vnncomp2023_benchmarks/benchmarks/cgan at main ChristopherBrix/vnncomp2023_benchmarks — github.com,” https://github.com/ChristopherBrix/vnncomp2023_benchmarks/tree/main/benchmarks/cgan, [Accessed 25-01-2024].
- [6] “Bashrc fix,” <https://discuss.pytorch.org/t/libcudnn-cnn-infer-so-8-library-can-not-found/164661>, [Accessed: 19.12.2023].
- [7] “Neuralsat install.md,” <https://github.com/dynaroars/neuralsat/blob/develop/INSTALL.md>, [Accessed: 15.02.2024].